

POC - Plateforme Big Data BigMedia

« « Apport du Big Data pour la direction de la programmation d'une chaîne de vidéo à la demande » »

SOMMAIRE

1	Introduction	2
1.1	But du document	2
2	Spécifications techniques	2
2.1	Solutions choisies	2
2.2	Architecture technique	2
2.3	Fichiers sources	3
2.4	Base de données	3
2.5	Modèle de données	4
2.6	Dictionnaire de données	4
2.7	Mapping de données	6
	Annexe	8

1.1 INTRODUCTION

1.1 But du document

Cette fiche a pour but de présenter les spécifications techniques du **Proof of Concept** (POC) pour la future plateforme Big Data de BigMedia. L'objectif de ce POC est de démontrer la faisabilité technique et la valeur métier du projet, afin de valider le concept et de convaincre la direction de la production d'investir dans une solution à plus grande échelle.

1.1 SPÉCIFICATIONS TECHNIQUES

2.1 Solutions choisies

Le POC évaluera des outils issus des catégories suivantes, identifiées comme nécessaires pour atteindre les objectifs de BigMedia. Les choix technologiques spécifiques seront validés durant cette phase.

- **Collecte et intégration de données (ELT)** : Outils pour extraire les données des systèmes sources (logs, API réseaux sociaux) et les charger dans notre base de données [1].
 - Pour le POC, un script Python (**seed_script.py**) génère des données synthétiques réalistes (**Faker**). Prefect orchestre ensuite l'ingestion de ces données vers le Data Lake [2]..
- **Stockage Big Data** : Solution capable de stocker des données structurées et non structurées.
 - Google Cloud Storage (GCS) est utilisé comme Data Lake pour le stockage des données brutes (couche Bronze), et Google BigQuery comme Data Warehouse pour les données modélisées (couche Gold) [3], [4].
- **Traitement de données** : Transformation des données brut vers des données nettoyées, en schéma en étoile (STAR schema) [5].
 - Prefect est utilisé pour orchestrer ces workflows dbt, qui sont ensuite exécuté sur BigQuery [6].
- **Data Visualisation** : Plateforme pour créer les tableaux de bord et les KPIs à destination des directions métiers.
 - Power BI est l'outil de BI choisi pour la création des tableaux de bord et la visualisation des KPIs [7].

2.2 Architecture technique

L'architecture du POC consiste en un pipeline de données centralisé qui ingère, stocke, traite et présente les données issues des différentes sources. L'accent sera mis sur la capacité à traiter à la fois des données structurées (logs de visionnage) et non structurées (commentaires, likes).

Description textuelle de l'architecture du POC :

Le pipeline de données est orchestré par **Prefect**.

1. Les données brutes (fichiers JSON et CSV) sont générées par un script Python (**seed_script.py**) simulant les systèmes sources.

2. Ce script charge ensuite ces fichiers dans un Data Lake sur **Google Cloud Storage** (couche Bronze).
3. **dbt** est ensuite utilisé pour transformer, nettoyer et modéliser les données brutes en un schéma en étoile optimisé pour l'analyse.
4. Les tables transformées (dimensions et faits) sont stockées dans **Google BigQuery** (couche Gold).
5. Enfin, **Power BI** se connecte à BigQuery pour permettre la visualisation des données et la création de tableaux de bord interactifs pour les équipes métiers.

2.3 Fichiers sources

Le périmètre du POC se concentre sur les jeux de données ci-dessous pour illustrer la chaîne de valeur.

Source	Description	Format	Remarques clés
viewing_logs.json	Événements de visionnage (session, utilisateur, contenu, appareil).	JSON (1 événement par ligne)	Source principale pour les métriques d'audience. Champs en snake_case.
contents.csv	Catalogue de contenus (métadonnées séries/épisodes).	CSV	Inclut duration_minutes et production_type pour les comparaisons Original vs Achat.
users.csv	Profil anonymisé des utilisateurs VoD.	CSV	Permet l'analyse par pays, tranche d'âge et ancienneté.
social_media_mentions.json	Mentions issues des réseaux sociaux.	JSON (1 mention par ligne)	Score de sentiment simulé pour le POC, futur NLP à intégrer.


2.4 Base de données

La base de données du POC devra stocker les données brutes extraites des sources ainsi que les données nettoyées et agrégées, prêtes pour l'analyse. Une solution flexible sera privilégiée pour s'adapter à la variété des formats.

- **Pour ce POC, nous utilisons Google BigQuery comme système de base de données. Il sert à la fois de destination pour les données transformées par dbt et de source unique de vérité pour l'outil de BI. Sa capacité à gérer de grands volumes de données et son intégration native avec l'écosystème Google Cloud en font un choix pertinent.**

2.5 Modèle de données

Le modèle de données ci-dessous représente la structure cible simplifiée pour les données qui seront exploitées dans le POC. Il se concentre sur les entités clés : utilisateurs, contenus, séries et événements.



Faits marquants :

- **FCT_Viewings** porte les métriques telles que la durée de visionnage, le taux de complétion et l'indicateur de visionnage complet.
- Les dimensions apportent le contexte (profil utilisateur, métadonnées contenu, série, appareil, calendrier) et facilitent les comparaisons Original BigMedia vs Achat.

2.6 Dictionnaire de données

Ce dictionnaire synthétise les champs clés exposés dans la couche Gold et ceux maintenus en staging pour les analyses complémentaires.

Table	Nom du champ	Description
FCT_Viewings	viewing_sk	Clé de substitution de l'événement de visionnage
FCT_Viewings	user_fk	Référence à la dimension utilisateur
FCT_Viewings	content_fk	Référence à la dimension contenu
FCT_Viewings	series_fk	Référence à la dimension série
FCT_Viewings	date_fk	Référence à la dimension date (format YYYYMMDD)
FCT_Viewings	device_fk	Référence à la dimension appareil
FCT_Viewings	view_duration_minutes	Durée de visionnage convertie en minutes
FCT_Viewings	completion_rate	Ratio durée visionnée / durée totale du contenu
FCT_Viewings	is_completed_view	Indicateur booléen si le visionnage dépasse 90 % du contenu

FCT_Viewings	start_timestamp	Horodatage de début de visionnage
FCT_Viewings	end_timestamp	Horodatage de fin de visionnage

Table	Nom du champ	Description
DIM_Users	user_sk	Clé de substitution utilisateur
DIM_Users	user_id	Identifiant métier pseudonymisé
DIM_Users	country	Pays de connexion de l'utilisateur
DIM_Users	age	Âge de l'utilisateur
DIM_Users	days_since_registration	Ancienneté en jours au moment du chargement
DIM_Content	content_sk	Clé de substitution contenu
DIM_Content	content_id	Identifiant métier du contenu
DIM_Content	title	Titre de l'épisode ou du film
DIM_Content	season_number	Numéro de la saison
DIM_Content	episode_number	Numéro de l'épisode
DIM_Content	release_date	Date de sortie
DIM_Content	release_year	Année de sortie
DIM_Content	duration_minutes	Durée du contenu en minutes
DIM_Content	production_cost_euros	Coût de production en euros
DIM_Series	series_sk	Clé de substitution série
DIM_Series	series_name	Nom de la série
DIM_Series	genre	Genre principal
DIM_Series	target_age_group	Groupe d'âge cible
DIM_Series	production_type	Type de production (Original BigMedia ou Achat)
DIM_Series	first_release_year	Année de première diffusion
DIM_Series	total_seasons	Nombre total de saisons
DIM_Devices	device_sk	Clé de substitution appareil
DIM_Devices	device_type	Catégorie d'appareil (TV, mobile, etc.)
DIM_Devices	os	Système d'exploitation
DIM_Date	date_sk	Clé calendrier (YYYYMMDD)
DIM_Date	full_date	Date complète
DIM_Date	is_weekend	Indicateur fin de semaine

Table staging	Nom du champ	Description
STG_Social_Mentions	mention_id	Identifiant unique de la mention
STG_Social_Mentions	content_title_mentioned	Titre normalisé mentionné dans le message

STG_Social_Mentions	sentiment_score	Score simulé (0: négatif, 1: neutre, 2: positif)
STG_Social_Mentions	publication_timestamp	Horodatage de la publication sur le réseau social

2.7 Mapping de données

Cette section décrit la correspondance entre les champs des fichiers sources et les champs du modèle de données cible pour le POC.

Source brute	Champ cible (staging)	Règle de transformation
viewing_logs.json.user_id	stg_viewing_logs .user_id	Mapping direct (snake_case conservé)
viewing_logs.json .content_id	stg_viewing_logs .content_id	Mapping direct
viewing_logs.json .watch_duration_seconds	stg_viewing_logs .watch_duration_seconds	Mapping direct (type INTEGER)
viewing_logs.json .start_timestamp	stg_viewing_logs .start_timestamp	Conversion au format TIMESTAMP BigQuery
contents.csv .duration_minutes	stg_contents .duration_minutes	Mapping direct (type INTEGER)
users.csv .registration_date	stg_users .registration_date	Conversion au format DATE
users.csv .country	stg_users .country	Standardisation des codes pays (FR, BE, CH)
social_media_mentions.json .mentions_text	stg_social_media .mentions_text	Nettoyage minimal (trim, suppression HTML)
social_media_mentions.json .mentions_sentiment	stg_social_media .sentiment_score	Simulation d'un score 0/1/2 en attendant une librairie NLP

Staging	Champ cible (Gold)	Règle de transformation
stg_viewing_logs .session_id	FCT_Viewings .viewing_sk	Génération d'une clé de substitution (combinaison session_id + user_id)
stg_viewing_logs .user_id	FCT_Viewings .user_fk	Jointure sur DIM_Users.user_id
stg_viewing_logs .content_id	FCT_Viewings .content_fk	Jointure sur DIM_Content.content_id
stg_viewing_logs .content_id	FCT_Viewings .series_fk	Jointure sur DIM_Series via DIM_Content
stg_viewing_logs .start_timestamp	FCT_Viewings .date_fk	Dérivation de la date YYYYMMDD et jointure sur DIM_Date
stg_viewing_logs .device_type	FCT_Viewings .device_fk	Jointure sur DIM_Devices (device_type + os)
stg_viewing_logs .os	DIM_Devices .os	Standardisation des libellés systèmes (Android TV, iOS, etc.)
stg_viewing_logs .watch_duration_seconds	FCT_Viewings .view_duration	Diminution par 60 et arrondi à deux décimales
stg_viewing_logs .watch_duration_seconds	FCT_Viewings .completion_rate	watch_duration_seconds / (stg_contents.duration_minutes * 60)

		60) avec gestion division par zéro
FCT_Viewings .completion_rate	FCT_Viewings .is_completed	CASE WHEN completion_rate >= 0.9 THEN TRUE ELSE FALSE END

ANNEXE

- [1] « ELT vs ETL: What's the Difference? ». [En ligne]. Disponible sur: <https://www.ibm.com/topics/elt>
- [2] Prefect Technologies Inc., « Prefect ». [En ligne]. Disponible sur: <https://www.prefect.io/>
- [3] « Google Cloud Platform ». [En ligne]. Disponible sur: <https://cloud.google.com/>
- [4] Google LLC, « Google BigQuery ». [En ligne]. Disponible sur: <https://cloud.google.com/bigquery>
- [5] Wikipedia, « STAR schema ». [En ligne]. Disponible sur: [https://fr.wikipedia.org/wiki/%C3%89toile_\(mod%C3%A8le_de_donn%C3%A9es\)](https://fr.wikipedia.org/wiki/%C3%89toile_(mod%C3%A8le_de_donn%C3%A9es))
- [6] dbt Labs, « Data Build Tool ». [En ligne]. Disponible sur: <https://www.getdbt.com/>
- [7] « Microsoft Power BI ». [En ligne]. Disponible sur: <https://powerbi.microsoft.com/>